

Sinh viên: Nguyễn Việt Anh – 20215307

Github dự án: <https://github.com/vieanh88/Project3>

Báo cáo tiến độ thực hiện Project 3

Đề tài: Xây dựng mô hình phân loại tài liệu đa ngôn ngữ

Sinh viên: Nguyễn Việt Anh – 20215307

Em chào thầy ạ, em xin phép gửi thầy báo cáo tiến độ của dự án em đã thực hiện trong 6 tuần vừa qua cho dự án phân loại ngôn ngữ tài liệu PDF:

Tuần 1: Thu thập dữ liệu

- Em thu thập qua google số lượng lớn đường link có chứa các file pdf của 4 ngôn ngữ (jp, kr, vn, us) bằng phương pháp search **google dorks**:

Em tìm kiếm kết hợp filetype:pdf + từ khoá + domain để tìm PDF. Ví dụ (nhập vào Google / Bing):


Tiếng Việt/Tiếng Anh/Japan/Korean:

filetype:pdf "nghiên cứu" site:.edu.vn

filetype:pdf site:.ac.jp "研究" (Nhật — “nghiên cứu”)

filetype:pdf site:.ac.kr "연구" (Hàn — “nghiên cứu”)


filetype:pdf "conference" site:.edu



- Sau khi thu được 1 bộ file seed.txt như ảnh em thực hiện code, viết 1 tool crawl pdf từ các đường dẫn tới các trang web đó và thực hiện chạy crawl trên nền tảng Google Colab.

Sinh viên: Nguyễn Việt Anh – 20215307

Github dự án: <https://github.com/vieanh88/Project3>



```
[ ]: from google.colab import drive
drive.mount('/content/drive')

... Mounted at /content/drive

[ ]: # Nếu thư viện đã có sẵn trên Colab thì pip sẽ báo đã cài.
# Thư viện requests + BeautifulSoup4 dùng để tải và parse HTML.
!pip install --quiet requests beautifulsoup4

[ ]: # Đặt thư mục base trên Drive để lưu kết quả (bạn có thể sửa đường dẫn này)
DRIVE_BASE = "/content/drive/My Drive/pdf_crawler_results/kr"
import os
os.makedirs(DRIVE_BASE, exist_ok=True)
print("Kết quả sẽ được lưu vào:", DRIVE_BASE)

... Kết quả sẽ được lưu vào: /content/drive/My Drive/pdf_crawler_results/kr

[ ]: # Các import cần thiết và cấu hình nhỏ (timeout, headers, delay)
import requests
from bs4 import BeautifulSoup
from urllib.parse import urljoin, urlparse
import time
import re
import os

# Cấu hình: header gửi kèm để trông giống trình duyệt (tốt khi crawling)
HEADERS = {
    "User-Agent": "Mozilla/5.0 (X11; Linux x86_64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/115.0 Safari/537.36"
}

# Giới hạn thời gian chờ request
REQUEST_TIMEOUT = 6 # giây

# Delay giữa các request để không làm quá tải server (hãy tôn trọng website)
REQUEST_DELAY = 0.2 # giây

[ ]: ## Kiểm tra và loại bỏ đường dẫn trùng lặp trong file txt
# - File gốc: thay đổi PATH_TXT nếu cần
# - In ra các đường dẫn trùng lặp trên màn hình (stdout) và ghi lại file txt không trùng


PATH_TXT = "/content/drive/My Drive/pdf_crawler_results/seeds.kr.txt" # <-- sửa lại đường dẫn nếu file txt nằm chỗ khác trong Colab/Drive

# Quan trọng: import thư viện chuẩn
from collections import Counter
```

- Em thực hiện crawl trên 200 page thuộc đường link (max_page=200) và tìm kiếm pdf, số lượng max pdf tải xuống được đặt là 100 cho 1 đường link thuộc file seeds.txt (max_pdf_downloads=100)

Sinh viên: Nguyễn Việt Anh – 20215307

Github dự án: <https://github.com/vieanh88/Project3>



```
# Tải xuống PDF
seeds_path = "/content/drive/My Drive/pdf_crawler_results/seeds_kr.txt"
with open(seeds_path, "r", encoding="utf-8") as f:
    seeds = [ln.strip() for ln in f if ln.strip()]

results = []
for s in seeds:
    print("Crawling:", s)
    res = crawl_site(start_urls=s, max_pages=200, download_pdfs=True, max_pdf_downloads=100)
    results.append(res)
    print("Domain:", res["domain"])
    print("Số link PDF:", len(res["pdf_links"]))

print("Downloaded files:", len(res["downloaded"]))
```

Crawling: <https://www.gosi.kr/>
[Phase 1] Thu thập PDF links từ tối đa 200 trang...
[Phase 1 DONE] Crawl xong. Trang đã duyệt: 200. Link PDF tìm thấy: 1.
File danh sách link: /content/drive/My Drive/pdf_crawler_results/kr/www.gosi.kr/pdf_links.txt

[Phase 2] Bắt đầu tải 1 file PDF...
[DL 1/1] https://www.gosi.kr/images/pop_2026_new.pdf -> pop_2026_new.pdf

[Phase 2 DONE] Số PDF đã tải về: 1
Domain: www.gosi.kr
Số link PDF: 1
Downloaded files: 1

Crawling: <https://www.alio.go.kr/>
[Phase 1] Thu thập PDF links từ tối đa 200 trang...
[Phase 1 DONE] Crawl xong. Trang đã duyệt: 160. Link PDF tìm thấy: 0.
File danh sách link: /content/drive/My Drive/pdf_crawler_results/kr/www.alio.go.kr/pdf_links.txt

[Phase 2] Bắt đầu tải 0 file PDF...

[Phase 2 DONE] Số PDF đã tải về: 0
Domain: www.alio.go.kr
Số link PDF: 0
Downloaded files: 0

Crawling: <https://www.law.go.kr/>
[Phase 1] Thu thập PDF links từ tối đa 200 trang...
[Phase 1 DONE] Crawl xong. Trang đã duyệt: 1. Link PDF tìm thấy: 0.
File danh sách link: /content/drive/My Drive/pdf_crawler_results/kr/www.law.go.kr/pdf_links.txt

[Phase 2] Bắt đầu tải 0 file PDF...

[Phase 2 DONE] Số PDF đã tải về: 0
Domain: www.law.go.kr
Số link PDF: 0
Downloaded files: 0

Crawling: <https://www.moef.go.kr/>
[Phase 1] Thu thập PDF links từ tối đa 200 trang...
/usr/local/lib/python3.12/dist-packages/bs4/_init_.py:476: XMLParsedAsHTMLWarning: It looks like you're using an HTML parser to parse an XML document.

Tuần 2: Lọc thủ công và review dữ liệu

- Vì dữ liệu crawl được bằng phương pháp trên là hoàn toàn chưa qua xử lý và review, nên xuất hiện tình trạng pdf bị lỗi trong thời gian tải cũng như các pdf xuất hiện sai ngôn ngữ.
- Em quyết định sử dụng ứng dụng pdf foxit lọc các pdf bị lỗi và ko thể mở được, xóa khỏi bộ dữ liệu, tiếp theo là lọc các pdf bị lỗi, sử dụng thư viện **pdfminer** duyệt qua toàn bộ pdf, in ra những pdf có text trích xuất được có leng=0, đây là những pdf bị lỗi ký tự hoặc lỗi định dạng mà thư viện không thể đọc được, tiếp tục xóa khỏi bộ dữ liệu.
- Tiếp theo em review thủ công bằng cách lọc các file pdf bị đánh sai label, vì e crawl pdf trên các trang web nước ngoài với tên miền vừa các nước đó, tuy nhiên sẽ xuất hiện khá nhiều trường hợp không mong muốn (**ví dụ: trang web tiếng Việt hoặc tiếng Nhật xuất hiện khá nhiều pdf bằng tiếng Anh hoặc chứa đa phần ngôn ngữ là tiếng Anh thay vì ngôn ngữ chuẩn, có thể do tiếng Anh là ngôn ngữ Quốc Tế**) vì thế nên bước này cần **review thủ công**, lọc các pdf bị đánh nhãn sai.

Sinh viên: Nguyễn Việt Anh – 20215307

Github dự án: <https://github.com/vieanh88/Project3>

Tuần 3: Nghiên cứu bài toán và Chốt mô hình

- Em dành thời gian nghiên cứu về Language Identification (LID). Thay vì dùng các phương pháp cũ như n-gram, em quyết định sử dụng kiến trúc **Transformer** để nắm bắt ngữ cảnh tốt hơn.
- Em chọn mô hình **XLM-RoBERTa Base** làm cốt lõi vì nó hỗ trợ đa ngôn ngữ cực tốt, đặc biệt là các dải Unicode của tiếng Nhật, Hàn và Việt.

Tuần 4: Xử lý dữ liệu & Chiến thuật Chunking

- Em chuyển đổi bộ dữ liệu khoảng **9,000 file PDF** đã được review hoàn chỉnh bằng thư viện phù hợp lần cuối cùng để trích xuất text từ pdf đã được lọc thủ công để chuẩn bị cho việc huấn luyện mô hình.
- Về kỹ thuật, em chuyển từ thư viện **pdfminer** (lúc đầu em đã nghiên cứu và sử dụng thư viện này, nhưng sau khi xem xét thủ công 1 phần nhỏ data được xử lý và thấy thư viện này không hề tốt cho ngôn ngữ tiếng Việt) xuất hiện hiện tượng bị lỗi các ký tự dấu phức tạp trong ngôn ngữ tiếng Việt, thư viện này chuyển đổi sai. Vì vậy em đã chuyển sang sử dụng thư viện **PyMuPDF (fitz)** để tăng tốc độ trích xuất văn bản lên gấp 5-10 lần cũng như khắc phục được lỗi chuyển đổi sai ký tự phức tạp đối với ngôn ngữ tiếng Việt.
- Để xử lý các tài liệu dài (vượt giới hạn 512 tokens), em đã triển khai chiến lược **Enhanced Chunking** (chia nhỏ văn bản kèm theo khoảng chồng lấp 200 ký tự) để không bị mất ngữ cảnh giữa các đoạn.

Tuần 5: Huấn luyện và Tối ưu hóa

- Em tiến hành Fine-tuning mô hình trên máy cá nhân (GPU RTX 3050Ti).
- Để mô hình chạy ổn trên card 4GB VRAM, em đã áp dụng kỹ thuật **Mixed Precision (FP16)** và **Gradient Accumulation**.
- Quá trình huấn luyện được em theo dõi qua **WandB**, hàm loss giảm đều và đạt độ hội tụ rất tốt sau 3 Epochs.

Tuần 6: Đánh giá kết quả & Hoàn thiện App

Sinh viên: Nguyễn Việt Anh – 20215307

Github dự án: <https://github.com/vieanh88/Project3>

- Kết quả trên tập Test đạt độ chính xác **98.93%**. Mô hình phân biệt tuyệt đối giữa nhóm chữ tượng hình (Nhật, Hàn) và chữ Latinh (Anh, Việt).
- Em đã đóng gói xong giao diện **Streamlit** cho phép người dùng upload PDF, tùy chỉnh tham số trích xuất và xem biểu đồ phân tích xác suất theo từng phân đoạn (Chunk Analytics).
- Tiếp theo em cũng cập nhật commit dự án lần cuối lên github ạ.
Link github cho dự án em xin phép để ở đây ạ:
<https://github.com/vieanh88/Project3>

Tình trạng hiện tại: Em đã hoàn thành báo cáo cuối kỳ và sản phẩm demo chạy ổn định rồi ạ.